


Coste de inferencia contra el presupuesto de tiempo real



Medido en lazo cerrado dentro del simulador (10 tiradas por política), no con un tensor sintético. Punto: mediana; línea: del mínimo al máximo; nube: las medidas individuales. Se descarta la primera llamada de cada política (485 y 198 ms), que es compilación de kernels. Ninguna de las 226 medidas se sale del presupuesto: los 60× de diferencia en parámetros cuestan 10× en latencia y aun así ambas caben con holgura.